

SKRIPSI — TEKNIK INFORMATIKA

# IMPLEMENTASI METODE PRINCIPAL COMPONENT ANALYSIS (PCA) UNTUK REDUKSI DIMENSI DATA PADA DATASET WINEQT

# PCA

**Ade Ayu Wandira**

NIM: 24260007

Program Studi Teknik Informatika  
Fakultas Teknik dan Ilmu Komputer  
Universitas Nahdlatul Ulama Indonesia — Jakarta 2026

*Simulasi Sidang Skripsi*

# AGENDA PRESENTASI

01

## Pendahuluan

Latar Belakang • Rumusan Masalah • Tujuan • Manfaat

02

## Tinjauan Pustaka

Machine Learning • PCA • StandardScaler • Explained Variance

03

## Dataset & Library

WineQT Dataset • Library Python yang Digunakan

04

## Metodologi Penelitian

Kerangka Berpikir • Alur Penelitian • Pengolahan Data

05

## Implementasi Program

Import → Dataset → EDA → Standarisasi → PCA → Visualisasi

06

## Hasil & Analisis

Explained Variance • Total EVR 45.77% • Perbandingan

07

## Kesimpulan & Saran

Simpulan penelitian dan rekomendasi pengembangan

# Latar Belakang

Perkembangan teknologi informasi mendorong peningkatan penggunaan data dalam bidang Machine Learning. Dataset dengan banyak fitur sering mengandung informasi berulang dan meningkatkan kompleksitas komputasi. Diperlukan teknik yang mampu mengurangi kompleksitas tanpa menghilangkan informasi utama.

## Dimensionalitas Tinggi

11 fitur numerik pada WineQT memiliki potensi korelasi antar atribut

## Kompleksitas Komputasi

Semakin banyak fitur → kebutuhan komputasi meningkat signifikan

## Informasi Berulang

Fitur-fitur yang saling berkaitan menyebabkan redundansi informasi

## SOLUSI

Penerapan metode Principal Component Analysis (PCA) pada Dataset WineQT untuk mereduksi 11 fitur menjadi 2 principal component yang mampu mempertahankan informasi penting dari data asli.

# Rumusan Masalah

1

**Bagaimana penerapan metode PCA untuk reduksi dimensi pada Dataset WineQT?**

Mengimplementasikan PCA step-by-step: preprocessing → standarisasi → transformasi principal component

2

**Bagaimana menentukan jumlah principal component yang optimal?**

Berdasarkan nilai Explained Variance Ratio dan Total Explained Variance

3

**Bagaimana hasil PCA dalam mengurangi fitur dengan tetap mempertahankan informasi penting?**

Evaluasi hasil reduksi dari 11 fitur menjadi 2 principal component

# Tujuan & Manfaat Penelitian

## TUJUAN PENELITIAN

1

Mengimplementasikan metode PCA sebagai teknik reduksi dimensi pada Dataset WineQT

2

Menganalisis nilai Explained Variance Ratio dan Total Explained Variance untuk menentukan jumlah principal component optimal

3

Menghasilkan data dengan dimensi lebih sederhana dari 11 fitur menjadi 2 principal component

## MANFAAT PENELITIAN

### Manfaat Akademis

Menambah wawasan dan kontribusi di bidang Machine Learning, khususnya penerapan PCA. Dapat menjadi referensi bagi mahasiswa maupun peneliti selanjutnya.

### Manfaat Praktis

Memberikan gambaran penerapan PCA untuk menyederhanakan data berfitur banyak dengan tetap mempertahankan informasi penting. Acuan teknik reduksi dimensi pada berbagai kasus Machine Learning.



# Landasan Teori

## Machine Learning

Cabang AI yang memungkinkan sistem mengenali pola dari data dan menghasilkan prediksi tanpa pemrograman khusus.

*Goodfellow et al., 2016*

## StandardScaler

Standarisasi data agar mean = 0 dan std dev = 1. Penting sebelum PCA agar semua fitur berkontribusi seimbang.

*Pedregosa et al., 2011*

## Reduksi Dimensi

Teknik menyederhanakan data dengan mengurangi jumlah fitur namun mempertahankan informasi penting. Terdiri dari feature selection dan feature extraction.

*Greenacre et al., 2022*

## Explained Variance Ratio

Mengukur kontribusi setiap principal component dalam menjelaskan variasi data asli.

*Greenacre et al., 2022*

## Principal Component Analysis (PCA)

Metode statistik yang mentransformasikan fitur asli menjadi principal component baru berdasarkan variasi data. PC pertama memiliki variasi terbesar.

*Greenacre et al., 2022*

## Total Explained Variance

Nilai kumulatif EVR seluruh PC — menunjukkan total informasi yang dipertahankan setelah reduksi dimensi.

*Greenacre et al., 2022*

# Dataset WineQT

Dataset WineQT diperoleh dari platform Kaggle dalam format CSV. Dataset ini berisi karakteristik fisik dan kimia dari sampel wine dengan fitur-fitur numerik yang memiliki kemungkinan adanya korelasi antar atribut, sehingga sesuai untuk dilakukan reduksi dimensi menggunakan metode PCA.

11 FITUR INPUT (X)

|                      |                  |             |                |           |                             |
|----------------------|------------------|-------------|----------------|-----------|-----------------------------|
| fixed acidity        | volatile acidity | citric acid | residual sugar | chlorides | free sulfur dioxide         |
| total sulfur dioxide | density          | pH          | sulphates      | alcohol   | quality (target — excluded) |

1,143

Baris Data

13

Total Kolom

11

Fitur Input (X)

Kaggle

Sumber

# Library Python yang Digunakan

## Pandas

```
import pandas as pd
```

Membaca dataset WineQT (CSV), pemeriksaan struktur data, pengecekan missing value, pengolahan DataFrame

## NumPy

```
import numpy as np
```

Mendukung proses komputasi numerik dan operasi matematika yang dibutuhkan dalam analisis data

## Matplotlib

```
import matplotlib.pyplot as plt
```

Membuat visualisasi Scatter Plot hasil PCA dan Scree Plot berdasarkan Explained Variance Ratio

## StandardScaler

```
from sklearn.preprocessing import StandardScaler
```

Standarisasi data agar mean = 0 dan std dev = 1 sebelum penerapan PCA

## PCA

```
from sklearn.decomposition import PCA
```

Melakukan reduksi dimensi dengan n\_components = 2, menghasilkan PC1 dan PC2


## IPython.display

```
from IPython.display import display
```

Menampilkan DataFrame dalam bentuk tabel yang lebih rapi pada Jupyter Notebook



# Kerangka Berpikir & Alur Penelitian



## HASIL REDUKSI DIMENSI

**11 → 2**

Fitur → PC

**45.77%**

Total Explained Variance

**81.82%**

Reduksi Dimensi

# Tahap 1 & 2: Import Library dan Membaca Dataset



```
# 1. IMPORT LIBRARY
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.preprocessing \
    import StandardScaler
from sklearn.decomposition \
    import PCA
from IPython.display import display

# 2. MEMBACA DATASET
data = pd.read_csv("WineQT.csv")
print("5 Data Pertama:")
display(data.head())
```

1

## Import Library

Mengimpor Pandas, NumPy, Matplotlib, StandardScaler, PCA, dan IPython.display sebagai pondasi implementasi.

2

## Membaca Dataset

Dataset WineQT.csv dibaca menggunakan pd.read\_csv() dari library Pandas.

3

## Tampilkan 5 Data Pertama

Fungsi head() digunakan untuk memastikan data berhasil dimuat dan mengetahui struktur awal dataset.

## Tahap 3–5: Informasi Dataset, Statistik Deskriptif & Missing Value

### 3. Informasi Dataset

```
● ● ●  
  
# Ukuran dataset  
print(f"Baris: {data.shape[0]}")  
print(f"Kolom: {data.shape[1]}")  
  
# Tabel informasi  
info_df = pd.DataFrame({  
    "Kolom": data.columns,  
    "Tipe": data.dtypes.astype(str),  
    "Jumlah": data.count().values  
})  
display(info_df)
```

### 4. Statistik Deskriptif

```
● ● ●  
  
# Menampilkan statistik  
# count, mean, std, min,  
# 25%, 50%, 75%, max  
  
display(data.describe())  
  
# Mencakup semua  
# kolom numerik:  
# 13 kolom
```

### 5. Cek Missing Value

```
● ● ●  
  
# Pengecekan missing value  
missing = pd.DataFrame({  
    "Kolom": data.columns,  
    "Missing": data.isnull()  
        .sum().values  
})  
display(missing)  
  
# Hasil: 0 missing value  
# pada semua kolom
```

Hasil: Dataset WineQT memiliki 1.143 baris × 13 kolom, seluruh kolom bertipe numerik (float64 / int64), dan tidak ditemukan missing value pada seluruh kolom. Data siap untuk tahap preprocessing selanjutnya.

# Tahap 6 & 7: Pemilihan Fitur dan Standarisasi Data



```
# 6. MEMILIH FEATURE
# Drop kolom quality & Id
X = data.drop(
    columns=["quality", "Id"]
)
display(X.head())
# Hasil: 11 kolom fitur

# 7. STANDARISASI DATA
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# Ubah ke DataFrame
X_scaled = pd.DataFrame(
    X_scaled,
    columns=X.columns
)
display(X_scaled.head())
```

## Pemilihan Fitur (Feature Selection)

Kolom quality (target/label) dan Id (identitas) dikeluarkan dari matriks fitur X. Tersisa 11 fitur numerik yang akan digunakan pada proses PCA.

## Alasan Excludes Quality & Id

quality adalah variabel target (label) bukan fitur. Id hanya berfungsi sebagai nomor identitas dan tidak memiliki kontribusi terhadap analisis.

## Standarisasi StandardScaler

Setiap fitur distandardisasi menjadi mean = 0 dan std dev = 1. PCA sangat sensitif terhadap perbedaan skala antar fitur; standarisasi memastikan kontribusi yang seimbang.

### SEBELUM STANDARISASI

Skala fitur berbeda-beda  
(misal: alcohol 8–15 vs sulphates 0.3–2.0)

### SETELAH STANDARISASI

Semua fitur: mean=0, std=1  
Setiap fitur berkontribusi seimbang pada PCA

## Tahap 8–10: Model PCA, Transformasi & Hasil Principal Component



```
# 8. MEMBUAT MODEL PCA
pca = PCA(n_components=2)
pca.fit(X_scaled)
print("Model PCA berhasil dibuat.")

# 9. TRANSFORMASI PCA
X_pca = pca.transform(X_scaled)
print("Data berhasil ditransformasi.")

# 10. HASIL PRINCIPAL COMPONENT
pca_df = pd.DataFrame(
    X_pca,
    columns=["PC1", "PC2"]
)
display(pca_df.head())
```

X\_scaled  
(1143 × 11)

PCA  
fit()

transform()

X\_pca  
(1143 × 2)

### n\_components = 2

PCA dibangun untuk menghasilkan tepat 2 principal component dari 11 fitur input.

### fit() — Belajar Pola

Model mempelajari arah variasi terbesar dari data terstandarisasi X\_scaled.

### transform() — Reduksi

Data diproyeksikan ke ruang 2 dimensi: menghasilkan X\_pca berukuran 1143 × 2.



# Tahap 11–12: Explained Variance Ratio & Total Explained Variance

```
# 11. EXPLAINED VARIANCE RATIO
evr = pca.explained_variance_ratio_


display(pd.DataFrame({
    "Principal Component":
        ["PC1", "PC2"],
    "Explained Variance Ratio":
        evr
}))

# 12. TOTAL EXPLAINED VARIANCE
total = evr.sum()
print(f"Total EVR: {total:.4f}")
```

## HASIL EXPLAINED VARIANCE


PC1

~28.3%



PC2

~17.4%



## TOTAL EXPLAINED VARIANCE

45.77%

Dari 11 fitur asli, 2 principal component mampu mempertahankan 45.77% variasi informasi Dataset WineQT. PC1 menyimpan variasi terbesar (~28.3%), diikuti PC2 (~17.4%).


# Tahap 13–14: Scatter Plot PCA dan Scree Plot

## 13. Scatter Plot PCA

Scatter Plot menampilkan distribusi 1.143 sampel wine dalam ruang 2 dimensi PCA. Sumbu X = PC1 (variasi terbesar), Sumbu Y = PC2. Setiap titik merepresentasikan satu data WineQT setelah reduksi dimensi.

## 14. Scree Plot

Scree Plot memvisualisasikan Explained Variance Ratio setiap PC. Sumbu X = urutan PC, Sumbu Y = Explained Variance Ratio. Penurunan nilai dari PC1 ke PC2 terlihat jelas pada grafik.



# Hasil Implementasi PCA pada Dataset WineQT

| Keterangan              | Sebelum PCA      | Sesudah PCA                       |
|-------------------------|------------------|-----------------------------------|
| Jumlah Fitur            | 11 fitur numerik | 2 principal component (PC1, PC2)  |
| Kompleksitas Data       | Lebih tinggi     | Lebih sederhana                   |
| Informasi Dipertahankan | 100%             | 45.77% (Total Explained Variance) |
| Efisiensi Pengolahan    | Standar          | Lebih efisien                     |
| Reduksi Dimensi         | —                | 81.82% pengurangan dimensi        |

Interpretasi Kinerja

PCA dievaluasi menggunakan Explained Variance Ratio dan Total Explained Variance — bukan akurasi/recall. Penggunaan 2 PC menghasilkan total EVR 45.77%.

Evaluasi Efektivitas

Reduksi dimensi berhasil mengurangi 81.82% jumlah fitur (11→2). Meskipun informasi berkurang, representasi data menjadi jauh lebih sederhana.

Pembahasan Temuan

Hasil sejalan tujuan PCA: mengurangi kompleksitas dengan mengubah fitur berkorelasi menjadi PC baru. Pengujian hanya pada WineQT tanpa perbandingan metode lain.



# Kesimpulan

01

Metode PCA berhasil diterapkan pada Dataset WineQT melalui tahapan: pengumpulan data → preprocessing → standarisasi StandardScaler → pembentukan principal component.

02

PCA mampu mengurangi jumlah fitur dari 11 fitur asli menjadi 2 principal component, menghasilkan penyederhanaan struktur data sebesar 81.82%.

03

Berdasarkan nilai Total Explained Variance, 2 principal component mempertahankan informasi sebesar 45.77% dari data awal — menunjukkan tingkat kehilangan informasi yang relatif besar namun tetap merepresentasikan variasi utama.

04

PCA dapat digunakan sebagai teknik preprocessing yang efektif untuk menghasilkan representasi data lebih sederhana dan efisien dalam proses analisis Machine Learning.

# Saran untuk Penelitian Selanjutnya

01

## Perbandingan Metode Reduksi Dimensi

Penelitian selanjutnya dapat membandingkan PCA dengan LDA (Linear Discriminant Analysis) atau t-SNE (t-Distributed Stochastic Neighbor Embedding) untuk mengetahui kelebihan dan kekurangan masing-masing.

03

## PCA sebagai Tahap Preprocessing Klasifikasi

Hasil reduksi dimensi menggunakan PCA dapat dimanfaatkan sebagai preprocessing sebelum penerapan algoritma ML seperti klasifikasi atau prediksi untuk melihat pengaruhnya terhadap kinerja model.

02

## Pengujian pada Dataset Berbeda

Pengujian dapat dilakukan menggunakan dataset lain yang memiliki lebih banyak fitur atau karakteristik data yang berbeda untuk mengetahui tingkat efektivitas PCA pada berbagai jenis data.

04

## Analisis Jumlah PC yang Bervariasi

Penelitian berikutnya dapat mencoba jumlah principal component yang berbeda untuk menemukan keseimbangan yang lebih baik antara tingkat reduksi dimensi dan jumlah informasi yang dapat dipertahankan.

# Terima Kasih

Sidang Skripsi — Program Studi Teknik Informatika  
Universitas Nahdlatul Ulama Indonesia

**Ade Ayu Wandira | 24260007**

*Implementasi Metode Principal Component Analysis (PCA)  
untuk Reduksi Dimensi Data pada Dataset WineQT*

**11 Fitur → 2 PC**

**45.77% Total EVR**

**81.82% Reduksi Dimensi**

Jakarta, 2026